

Beyond Empathy by Correlation

Ku inkluzywnej robotyce afektywnej w realnej interakcji

dr inż. Mateusz Pomianek

Katedra Informatyki i Automatyki
Politechnika Rzeszowska



Dlaczego afektywna robotyka humanoidalna?

Nowe role robotów

Edukacja, terapia, opieka i przestrzeń domowa: sukces zależy nie tylko od wykonania zadania, ale od jakości percepcji i bezpieczeństwa emocjonalnego.

Oczekiwania społeczne

Humanoidy prowokują interpretację interpersonalną: gest, spojrzenie, proksemika i timing są odczytywane jak sygnały partnera społecznego.

Rosnące możliwości

Stan pola jest mocny technicznie: 92.1% F1 w ECRP, 97% w dialogu live i +12.5% po uczeniu interaktywnym, ale to nie rozwiązuje problemu wdrożenia.

Kluczowa teza: kompetencja techniczna musi być uzupełniona epistemiczną pokorą, partycypacyjnym projektowaniem i zasadami potwierdzającymi neuroróżnorodność.

Luka benchmark, a wdrożenie

Środowisko testowe

- kontrolowane datasety
- pozowane lub aktorskie ekspresje
- wąska pula uczestników
- uproszczone warunki sensoryczne
- metryki: accuracy, F1, latency



Środowisko wdrożenia

- zmienność kontekstowa i szum
- stany afektywne zmieszane z zadaniem
- użytkownicy neurozróżnicowani
- shift dystrybucji względem treningu
- koszty: godność, bezpieczeństwo, dobrostan


Porażka w robotyce afektywnej nie jest neutralna: błędna interpretacja może skierować doświadczenie użytkownika w stronę odwrotną do intencji systemu.

Architektury emocji

1 PRZEPŁYW INFORMACJI I PODEJMOWANIE DECYZJI


✗ SYSTEM KORELACYJNY

Podejście korelacyjne (czarna skrzynka)



✓ ARCHITEKTURA PRZYZYNOWO-KONTEKSTOWA


Wnioskowanie z uwzględnieniem przyczyn i kontekstu



2 PORÓWNANIE WŁAŚCIWOŚCI ARCHITEKTUR

KRYTERIUM	SYSTEM KORELACYJNY (czarna skrzynka)	ARCHITEKTURA PRZYZYNOWO-KONTEKSTOWA
Źródło sygnału	Płaskie cechy z danych (statystyczne współwystępowanie)	Wielomodalne + kontekst + wiedza (przyczyny)
Mechanizm	Dopasowanie wzorca (fitting korelacji)	Wnioskowanie przyczynowe (model świata / SCM / DBN)
Uogólnianie (O.O.D.)	Słabe	Silne (lepsza odporność na zmianę kontekstu)
Odporność na fałszywe skróty	Niska	Wysoka
Kalibracja pewności	Często źle skalibrowana	Jawna, możliwa do kalibracji
Wyjaśnialność	Niska (nieprzejrzyste decyzje)	Wysoka (jawne przyczyny i zależności)
Bezpieczeństwo	Niskie (brak mechanizmu abstencji)	Wysokie (abstencja / eskalacja / weryfikacja)

PROFIL ARCHITEKTUR (skala 0–5)



Affective loop jako rdzeń interakcji

1. REPREZENTACJE EMOCJI – JAK MODELE ROZUMIEJĄ AFEKT?

A. MODELE DYSKRETNE


Kategorie podstawowe
(np. Ekman, Plutchik)



+ interpretowalność
– sztywne granice

B. MODELE WYMIAROWE


Przestrzeń ciągła
(np. valence-arousal-dominance)



+ uchwyt dynamiki
– trudniejsza interpretacja

C. MODELE KONSTRUKTYWISTYCZNE


Emocje jako konstrukty
znaczeniowe i społeczne



+ kontekst i znaczenie
– zależność od ramy

D. MODELE HYBRYDOWE

Połączenie kategorii,
wymiarów i kontekstu



+ elastyczność
i bogactwo
– złożoność obliczeniowa

2. AFFECTIVE LOOP – RDZEŃ INTERAKCJI

1. PERCEPCJA

Multimodalne sygnały
(twarz, głos, ciało,
słowa, fizjologia, kontekst)



2. INFERENCJA AFEKTYWNA

Estymacja stanu afektywnego
(reprezentacja emocji)



3. DECYZJA AFEKTYWNA

Wybór reakcji zgodnej
z celem i normami
społecznymi



4. AKCJA SYSTEMU

(werbalna, niewerbalna,
behawioralna)



6. AKTUALIZACJA

Uczenie online,
aktualizacja modelu
użytkownika



5. REAKCJA UŻYTKOWNIKA

Odpowiedź na działanie
systemu (zmiana stanu)



Ciągłe współ-kształtowanie stanu afektywnego i relacji

3A. ŚRODOWISKO TESTOWE (LABORATORYJNE)

- ✓ Dobre oczyszczenie danych
- ✓ Czytelne wyrażenia emocji
- ✓ Ograniczona pula uczestników
- ✓ Często neurotypowi uczestnicy
- ✓ Uproszczone warunki sensoryczne
- ✓ Kontrolowany kontekst zadania

METRYKI KLASYCZNE



Accuracy

F1-score

Sensowne w warunkach i.i.d.
i przy stabilnej dystrybucji danych

PRZEJŚCIE
DO RZECZYWISTEGO
WDROŻENIA

---+---
Distribution Shift
i złożoność świata

3B. ŚRODOWISKO WDROŻENIA (REAL-WORLD)

- ⚠ Afekt miesza się z zadaniem i kontekstem
- ⚠ Przeciążenie sensoryczne, zakłócenia
- ⚠ Historia interakcji i oczekiwania
- ⚠ Różnice indywidualne i kulturowe
- ⚠ Szum, ambiguitas i niepełne obserwacje
- ⚠ Distribution shift (czasu, miejsca, populacji)

WCZORAJ TRAFNY MODEL MOŻE:

- ⊗ generować nieadekwatne reakcje
- ⊗ być nierobustny wobec nowych użytkowników
- ⊗ utrzymywać uprzedzenia i wykluczenia
- ⊗ nie wychwycić realnego distressu
- ⊗ nadmiernie interweniować lub intrudować

METRYKI NIETYRZARZAJĄCE



Nie odzwierciedlają skutków
społecznych i bezpieczeństwa

4. PORĄŻKA W ROBOTYCE AFEKTYWNEJ NIE JEST NEUTRALNA

FAŁSZYWY DISTRESS (FP)



Ryzyko: intruzyjna interwencja,
utrata zaufania, eskalacja stresu

FAŁSZYWE ZAANGAŻOWANIE (FN)



Ryzyko: przeoczenie przeciążenia,
pogorszenie dobrostanu, możliwa szkoda

PYTANIE METODOLOGICZNE, NIE TYLKO TECHNICZNE:



„Czy model jest trafny?”

czy raczej

„Czy potrafi fail gracefully
w sytuacji społecznie wrażliwej?”

5. ZASADY PROJEKTOWE DLA PĘTLI AFEKTYWNEJ



- Uprzywilejowanie bezpieczeństwa społecznego – minimalizacja ryzyk niekorzystnych skutków.
- Kalibracja niepewności i świadomość ograniczeń – pewność modelu ≠ pewność decyzji.
- Projektowanie dla abstencji i dopytania – „nie wiem” jest lepsze niż błąd kosztowny.
- Personalizacja i uczenie relacyjne – poznawanie użytkownika w czasie.
- Wielowymiarowa ewaluacja – skuteczność, dobrostan, zaufanie, sprawiedliwość, nierówności.

Koszt błędu w robotyce afektywnej

False positive

System błędnie przypisuje użytkownikowi stan afektywny.

Ryzyko

intruzywna lub nieadekwatna interwencja, naruszenie komfortu i godności.

False negative

System nie rozpoznaje rzeczywistego przeciążenia, stresu lub dystresu.

Ryzyko

brak wsparcia tam, gdzie jest ono potrzebne; eskalacja napięcia.

Uncertainty failure


System komunikuje kruchą inferencję z nadmierną pewnością.

Ryzyko

użytkownik traktuje zawodny osąd jako wiarygodny; spadek bezpieczeństwa interakcji.

W **HRI** nie wystarczy pytać, **czy model jest trafny**; trzeba pytać, **czy potrafi bezpiecznie mylić** się w sytuacjach społecznie wrażliwych.

Asymetria epistemiczna w „Empatii przez korelację”



Neuroróżnorodność, jako ograniczenie projektowe

1. NEURORÓŻNORODNOŚĆ W LICZBACH



15–20%

ludzi na świecie jest
neuroróżnorodnych.



To ponad 1 miliarda osób.
To nie margines. To
mniejszość.

Najczęściej występujące różnice neurokognitywne



DYSLEKSJA

5–10%



AUTYZM

1–2%



ADHD

2–5%



DYSKALKULIA

3–6%



ZABURZENIA
PRZETWARZANIA
SENSORYCZNEGO

5–16%



ZABURZENIA
LĘKOWE

10–20%



~30%

INFORMATYKÓW jest neuroróżnorodnych.
Ich różnorodność poznawcza napędza innowacje
i rozwiązywanie problemów.

Źródła: WHO, UNICEF, CDC, OECD, badania populacyjne 2020–2024; HBR, Microsoft, 2023.

2. FAKT BIOLOGICZNY vs PARADYGMAT

FAKT BIOLOGICZNY:
NEURORÓŻNORODNOŚĆ



VS

PARADYGMAT:
PERSPEKTYWA
NEURORÓŻNORODNOŚCI



- ✓ Naturalna, nieskończona zmienność ludzkich umysłów.
- ✓ Obiektywny stan rzeczy.
- ✓ Nie jest ruchem społecznym ani przekonaniem.
- ✓ Po prostu JEST – tak jak różnorodność biologiczna.

- ✓ Sposób rozumienia i reagowania na ten fakt.
- ✓ Zakotwiczenie w prawach osób z niepełnosprawnościami i modelu społecznym.
- ✓ Odrzuca „naprawianie” i „leczenie” jednostek.
- ✓ Wzywa do zmian systemowych, dostępności i autonomii.



Fakt to różnorodność mózgów.

Paradygmat to wybór: szacunek, sprawiedliwość i równość.

3. FILARY PARADYGMATU NEURORÓŻNORODNOŚCI



PRAWA I SPRAWIEDLIWOŚĆ

Zakotwiczenie w prawach osób z niepełnosprawnościami i w społecznym modelu niepełnosprawności.



RÓŻNICE SĄ NATURALNE

Różnice neurologiczne to naturalna i istotna część ludzkiej bioróżnorodności, a nie błędy do naprawy.



KONIEC MEDYCZYNY NAPRAWCZEJ

Sprzeciw wobec oczekiwania, że jednostki mają „pokonać”, „wyleczone” lub „naprawione”.



ODPOWIEDZIALNOŚĆ SPOŁECZEŃSTWA

To społeczeństwo musi się dostosować: dostępność, usuwanie barier, likwidacja ableizmu.



AUTONOMIA I PRZYNALEŻNOŚĆ

Szacunek dla sposobu funkcjonowania, autonomii i prawa do pełnego uczestnictwa w społeczeństwie.

4. MODEL MEDYCZNY vs MODEL SPOŁECZNY

MODEL MEDYCZNY

Problem leży w jednostce

MODEL SPOŁECZNY

Problem leży w barierach



- ✗ Deficyt do naprawy
- ✗ Diagnostyka i terapia
- ✗ „Naprawa” lub „normalizacja”
- ✗ Terapie behawioralne
- ✗ Presja na konformizm

VS



- ✓ Bariery w środowisku
- ✓ Dostępność i równość
- ✓ Zmiany systemowe
- ✓ Usuwanie barier
- ✓ Autonomia i wybór



Nie zmieniamy ludzi. Zmieniamy świat.

5. SKUTKI BRAKU ZMIAN SYSTEMOWYCH



70%

osób autystycznych doświadcza problemów ze zdrowiem psychicznym (lęk, depresja) z powodu barier społecznych i systemowych.



85%

młodych osób neuroróżnorodnych doświadcza wykluczenia w edukacji przynajmniej raz w swojej ścieżce szkolnej.



>50%

osób neuroatypowych jest bezrobotnych lub niedostatecznie zatrudnionych.



2–2,5x

większe ryzyko myśli samobójczych u osób neuroróżnorodnych w porównaniu do populacji ogólnej.

Źródła: WHO, CDC, UNICEF, OECD, Lancet Psychiatry, 2020–2024

6. PRAWDZIWE WSPARCIE (NEURO-AFFIRMING PRACTICE)



**DOSTĘPNOŚĆ
SENSORYCZNA**

Przestrzenie i narzędzia dostosowane do potrzeb sensorycznych.



**DOSTĘPNOŚĆ
SPOŁECZNA**

Równe traktowanie, brak dyskryminacji, akceptacja różnic komunikacyjnych.



**ZMIANA
SYSTEMOWA**

Likwidacja barier i polityk wykluczających.



**AUTONOMIA
I WYBÓR**

Szacunek dla decyzji, granic i sposobu funkcjonowania.



**UDZIAŁ OSÓB
NEURORÓŻNORODNYCH**

Współtworzenie rozwiązań z osobami, których dotyczą decyzje.



**PRZYNALEŻNOŚĆ
BEZ WARUNKÓW**

Poczucie przynależności niezależnie od poziomu produktywności.

Przykłady systemów neurodiversity-sensitive

Neurodiversity-AWARE

Rozpoznaje różnice w stylach komunikacji i profilach sensorycznych; unika założenia jednego wzorca normatywnego.

Neurodiversity-SENSITIVE

Modyfikuje zachowanie systemu w odpowiedzi na te różnice: tempo, kanał sensoryczny, styl promptowania.

Neurodiversity-AFFIRMING

Traktuje odmienność jako legalną wariację, a nie deficyt do korekty. Zmienia funkcję celu i kryteria ewaluacji.

Problem podwójnej empatii (Milton, 2012): robot zoptymalizowany pod jeden wzorec interakcji staje się nieprzejrzysty dla użytkowników ukształtowanych przez inną normę.

Ramy inkluzywne: 6 wymiarów

1. Percepcja i niepewność

inference pod niepewnością, abstention, calibration

2. Czytelność afordancji

jak robot komunikuje stan, intencje i granice

3. Personalizacja i adaptacja

user-specific regularities, tempo, kanał, intensywność

4. Wnioskowanie przyczynowe

od sygnału do wyjaśnienia: overload, frustracja, przemęczenie

5. Neuroróżnorodność

różne normy komunikacji jako wymóg projektowy

6. Ewaluacja i dobrostan

accuracy + kalibracja + komfort + autonomia + godność

Przejdźcie od empatii przez korelację do systemów, które są zarazem **trafne, kalibrowane, zrozumiałe i bezpieczne psychologicznie.**

Filary techniczne i architektura systemu

Architektura warstwowa

Percepcja

integracja multimodalna +
estymacja stanu z niepewnością

Personalizacja

priory i parametry specyficzne
dla użytkownika

Decyzja

polityka działania względem
afektu i ryzyka kontekstowego

Ekspresja

czas, postawa, gaze
i strategia werbalna

Trzy filary techniczne

1. Dane + niepewność

Dataset reprezentatywny, confidence
thresholds, abstention i escalation.

2. Personalizacja online

Brak jednego mapowania sygnał→znaczenie;
adaptacja tempa, kanału i intensywności.

3. Przyczynowość + ewaluacja

Accuracy to za mało: potrzebne kalibracja,
komfort, autonomia i dobrostan.

Konsekwencja dla inżynierii: system musi regulować nie tylko to, co wnioskuje,
ale także jak pewnie na tym działa i jak łatwo daje się skorygować użytkownikowi.

Przykłady systemów neurodiversity-sensitive

KASPAR

minimalistyczny humanoid

Projekt rozwijany przez lata zgodnie z wymaganiami użytkowników. Terapia i edukacja dzieci z ASD; wzorzec user-driven design.

(A)MICO

urządzenie multimodalne

Co-design z pracownikami autystycznymi. Redukcja przestymulowania i wzrost inkluzji w miejscu pracy.

JARI

modularny robot zoomorficzny


Utrzymane zaangażowanie u dzieci z ASD. Ambiwalentna forma zmniejsza presję interpretacyjną i ułatwia kontakt.

CoCoCo / Co3

zestawy do co-designu

Dorośli autystyczni mogą współprojektować roboty, jeśli dostarczymy scaffolding i naprawdę inkluzyjny proces.

Dynamiczny model emocji, dynamic Bayesian Network



Notacja

- z_t – stan emocjonalny (ukryty)
- C_t – kontekst w chwili t
- x_t – wektor sygnałów (wielomodalny)
- o_t – wektor obserwacji (cechy)
- a_t – działanie agenta (opcjonalnie kontrolujące przejścia i sygnały)


Faktoryzacja wspólnej dystrybucji (łańcuch Markowa 1. rzędu)

$$P(z_{1:T}, x_{1:T}, o_{1:T} | C_{1:T}, a_{1:T-1}) = P(z_1 | C_1) \prod_{t=1}^{T-1} P(z_{t+1} | z_t, C_t, a_t) \prod_{t=1}^T P(x_t | z_t, C_t, a_t) P(o_t | x_t)$$


Założenia modelu

- Emocja jest stanem ukrytym zmieniającym się w czasie.
- Kontekst wpływa zarówno na emocję, jak i na generację sygnałów.
- Sygnały (wielomodalne) są generowane przez emocję w danym kontekście.
- Obserwacje są funkcją sygnałów (np. cech ekstrakcyjnych).

World models: VAE → MDM-RNN → Controller



ECPR: Emotion-context reinforced planner



LEGENDA

- Przepływ główny
- - -> Przepływ informacji (alternatywny)
- - -> Uczenie / sprzężenie zwrotne

BELIEF STATE b_t

Rozkład probabilistyczny nad stanem ukrytym:

$$b_t(s_t) = P(s_t | o_t, m_t)$$

$$s_t = (e_t, i_t, n_t, r_t, c_t, q_t)$$

FUNKCJA NAGRODY R (EMOCJONALNO-KONTEKSTOWA)

Adekwatność emocjonalna	Spójność społeczna	Skuteczność zadaniowa	Bezpieczeństwo / ryzyko	Koszt wysiłku
R_{emo}	R_{soc}	R_{task}	R_{risk}	R_{effort}
😊	👥	🎯	🛡️	🕒




ZAMKNIĘTA PĘTLA ECPR

- Ciągła obserwacja i aktualizacja belief state
- Planowanie w oparciu o kontekst i emocje
- Jawną bramką epistemiczną (bezpieczeństwo poznawcze)
- Uczenie z nagrody zależnej od adekwatności emocjonalnej

KORZYŚCI


- Mniej błędnych reakcji
- Większe zaufanie użytkownika
- Naturalne, empatyczne interakcje
- Bezpieczne i adaptacyjne działanie

CASIE-2: Architektura przyczynowo-kontekstowa emocji




Architektura z epistemiczną pokorą

Pełny potok decyzyjny: od wejścia multimodalnego do działania, dopytania lub abstencji



Autorski framework: SAPIENS

Socially-aware, probalistic, intent-aware, epistemically-calibrated, neuro-symbolic system



Wnioski

- Robotyka afektywna musi wyjść poza empatię przez korelację.
- Trzy główne bariery to luka benchmark–wdrożenie, asymetria epistemiczna i nieadekwatność ewaluacji.
- Neuroróżnorodność nie jest przypadkiem brzegowym, lecz pierwszorzędowym ograniczeniem projektowym.
- Ramy inkluzywne łączą percepcję probabilistyczną, skalibrowaną niepewność, personalizację i wnioskowanie przyczynowe.
- Sukces systemu to nie tylko trafność klasyfikacji, ale zachowanie godności, redukcja stresu i wsparcie dobrostanu użytkownika.