

Beyond Empathy by Correlation

Ku inkluzywnej robotyce afektywnej w realnej interakcji

dr inż. Mateusz Pomianek

Katedra Informatyki i Automatyki
Politechnika Rzeszowska



Dlaczego afektywna robotyka humanoidalna?

Nowe role robotów

Edukacja, terapia, opieka i przestrzeń domowa: sukces zależy nie tylko od wykonania zadania, ale od jakości percepcji i bezpieczeństwa emocjonalnego.

Oczekiwania społeczne

Humanoidy prowokują interpretację interpersonalną: gest, spojrzenie, proksemika i timing są odczytywane jak sygnały partnera społecznego.

Rosnące możliwości

Stan pola jest mocny technicznie: 92.1% F1 w ECRP, 97% w dialogu live i +12.5% po uczeniu interaktywnym, ale to nie rozwiązuje problemu wdrożenia.

Kluczowa teza: kompetencja techniczna musi być uzupełniona epistemiczną pokorą, partycypacyjnym projektowaniem i zasadami potwierdzającymi neuroróżnorodność.

Luka benchmark, a wdrożenie

Środowisko testowe

- kontrolowane datasety
- pozowane lub aktorskie ekspresje
- wąska pula uczestników
- uproszczone warunki sensoryczne
- metryki: accuracy, F1, latency





Środowisko wdrożenia

- zmienność kontekstowa i szum
- stany afektywne zmieszane z zadaniem
- użytkownicy neurozróżnicowani
- shift dystrybucji względem treningu
- koszty: godność, bezpieczeństwo, dobrostan

Porażka w robotyce afektywnej nie jest neutralna: błędna interpretacja może skierować doświadczenie użytkownika w stronę odwrotną do intencji systemu.


Architektury emocji

1 PRZEPŁYW INFORMACJI I PODEJMOWANIE DECYZJI



2 PORÓWNANIE WŁAŚCIWOŚCI ARCHITEKTUR

KRYTERIUM	SYSTEM KORELACYJNY (czarna skrzynka)	ARCHITEKTURA PRZYZYNOWO-KONTEKSTOWA
Źródło sygnału	Płaskie cechy z danych (statystyczne współwystępowanie)	Wielomodalne + kontekst + wiedza (przyczyny)
Mechanizm	Dopasowanie wzorca (fitting korelacji)	Wnioskowanie przyczynowe (model świata / SCM / DBN)
Uogólnianie (O.O.D.)	Słabe	Silne (lepszą odporność na zmianę kontekstu)
Odporność na fałszywe skróty	Niska	Wysoka
Kalibracja pewności	Często źle skalibrowana	Jawna, możliwa do kalibracji
Wyjaśnialność	Niska (nieprzejrzyste decyzje)	Wysoka (jawne przyczyny i zależności)
Bezpieczeństwo	Niskie (brak mechanizmu abstencji)	Wysokie (abstencja / eskalacja / weryfikacja)



Affective loop jako rdzeń interakcji

1. REPREZENTACJE EMOCJI – JAK MODELE ROZUMIEJĄ AFEKT?

A. MODELE DYSKRETNE


Kategorie podstawowe
(np. Ekman, Plutchik)



+ interpretowalność
– sztywne granice

B. MODELE WYMIAROWE


Przestrzeń ciągła
(np. valence-arousal-dominance)



+ uchwyt dynamiki
– trudniejsza interpretacja

C. MODELE KONSTRUKTYWISTYCZNE


Emocje jako konstrukty
znaczeniowe i społeczne



+ kontekst i znaczenie
– zależność od ramy

D. MODELE HYBRYDOWE

Połączenie kategorii,
wymiarów i kontekstu



+ elastyczność
i bogactwo
– złożoność obliczeniowa

2. AFFECTIVE LOOP – RDZEŃ INTERAKCJI

1. PERCEPCJA

Multimodalne sygnały
(twarz, głos, ciało,
słowa, fizjologia, kontekst)



2. INFERENCJA AFEKTYWNA

Estymacja stanu afektywnego
(reprezentacja emocji)



3. DECYZJA AFEKTYWNA

Wybór reakcji zgodnej
z celem i normami
społecznymi



4. AKCJA SYSTEMU

(werbalna, niewerbalna,
behawioralna)



6. AKTUALIZACJA

Uczenie online,
aktualizacja modelu
użytkownika



5. REAKCJA UŻYTKOWNIKA

Odpowiedź na działanie
systemu (zmiana stanu)



Ciągłe współ-kształtowanie stanu afektywnego i relacji

3A. ŚRODOWISKO TESTOWE (LABORATORYJNE)

- ✓ Dobre oczyszczenie danych
- ✓ Czytelne wyrażenia emocji
- ✓ Ograniczona pula uczestników
- ✓ Często neurotypowi uczestnicy
- ✓ Uprozczone warunki sensoryczne
- ✓ Kontrolowany kontekst zadania

METRYKI KLASYCZNE



Accuracy

F1-score

Sensowne w warunkach i.i.d.
i przy stabilnej dystrybucji danych

PRZEJŚCIE
DO RZECZYWISTEGO
WDROŻENIA

---+---
Distribution Shift
i złożoność świata

3B. ŚRODOWISKO WDROŻENIA (REAL-WORLD)

- ⚠ Afekt miesza się z zadaniem i kontekstem
- ⚠ Przeciążenie sensoryczne, zakłócenia
- ⚠ Historia interakcji i oczekiwania
- ⚠ Różnice indywidualne i kulturowe
- ⚠ Szum, ambiguitas i niepełne obserwacje
- ⚠ Distribution shift (czasu, miejsca, populacji)

WCZORAJ TRAFNY MODEL MOŻE:

- ⊗ generować nieadekwatne reakcje
- ⊗ być nierobustny wobec nowych użytkowników
- ⊗ utrzymywać uprzedzenia i wykluczenia
- ⊗ nie wychwycić realnego distressu
- ⊗ nadmiernie interweniować lub intrudować

METRYKI NIETYRZARZAJĄCE



Nie odzwierciedlają skutków
społecznych i bezpieczeństwa

4. PORĄŻKA W ROBOTYCE AFEKTYWNEJ NIE JEST NEUTRALNA

FAŁSZYWY DISTRESS (FP)



Ryzyko: intruzyjna interwencja,
utrata zaufania, eskalacja stresu

FAŁSZYWE ZAANGAŻOWANIE (FN)



Ryzyko: przeoczenie przeciążenia,
pogorszenie dobrostanu, możliwa szkoda

PYTANIE METODOLOGICZNE, NIE TYLKO TECHNICZNE:



„Czy model jest trafny?”

czy raczej

„Czy potrafi fail gracefully
w sytuacji społecznie wrażliwej?”

5. ZASADY PROJEKTOWE DLA PĘTLI AFEKTYWNEJ



- Uprzywilejowanie bezpieczeństwa społecznego – minimalizacja ryzyk niekorzystnych skutków.
- Kalibracja niepewności i świadomość ograniczeń – pewność modelu ≠ pewność decyzji.
- Projektowanie dla abstencji i dopytania – „nie wiem” jest lepsze niż błąd kosztowny.
- Personalizacja i uczenie relacyjne – poznawanie użytkownika w czasie.
- Wielowymiarowa ewaluacja – skuteczność, dobrostan, zaufanie, sprawiedliwość, nierówności.

Koszt błędu w robotyce afektywnej

False positive

System błędnie przypisuje użytkownikowi stan afektywny.

Ryzyko

intruzywna lub nieadekwatna interwencja, naruszenie komfortu i godności.

False negative

System nie rozpoznaje rzeczywistego przeciążenia, stresu lub dystresu.

Ryzyko

brak wsparcia tam, gdzie jest ono potrzebne; eskalacja napięcia.

Uncertainty failure


System komunikuje kruchą inferencję z nadmierną pewnością.

Ryzyko

użytkownik traktuje zawodny osąd jako wiarygodny; spadek bezpieczeństwa interakcji.

W **HRI** nie wystarczy pytać, **czy model jest trafny**; trzeba pytać, **czy potrafi bezpiecznie mylić** się w sytuacjach społecznie wrażliwych.

Asymetria epistemiczna w „Empatii przez korelację”



Neuroróżnorodność, jako ograniczenie projektowe

1. NEURORÓŻNORODNOŚĆ W LICZBACH



15–20%

ludzi na świecie jest
neuroróżnorodnych.



To ponad 1 miliarda osób.
To nie margines. To
mniejszość.

Najczęściej występujące różnice neurokognitywne



DYSLEKSJA

5–10%



AUTYZM

1–2%



ADHD

2–5%



DYSKALKULIA

3–6%



ZABURZENIA
PRZETWARZANIA
SENSORYCZNEGO

5–16%



ZABURZENIA
LĘKOWE

10–20%



~30%

INFORMATYKÓW jest neuroróżnorodnych.
Ich różnorodność poznawcza napędza innowacje
i rozwiązywanie problemów.

Źródła: WHO, UNICEF, CDC, OECD, badania populacyjne 2020–2024; HBR, Microsoft, 2023.

2. FAKT BIOLOGICZNY vs PARADYGMAT

FAKT BIOLOGICZNY:
NEURORÓŻNORODNOŚĆ



VS

PARADYGMAT:
PERSPEKTYWA
NEURORÓŻNORODNOŚCI



- ✓ Naturalna, nieskończona zmienność ludzkich umysłów.
- ✓ Obiektywny stan rzeczy.
- ✓ Nie jest ruchem społecznym ani przekonaniem.
- ✓ Po prostu JEST – tak jak różnorodność biologiczna.

- ✓ Sposób rozumienia i reagowania na ten fakt.
- ✓ Zakotwiczenie w prawach osób z niepełnosprawnościami i modelu społecznym.
- ✓ Odrzuca „naprawianie” i „leczenie” jednostek.
- ✓ Wzywa do zmian systemowych, dostępności i autonomii.



Fakt to różnorodność mózgów.

Paradygmat to wybór: szacunek, sprawiedliwość i równość.

3. FILARY PARADYGMATU NEURORÓŻNORODNOŚCI



PRAWA I SPRAWIEDLIWOŚĆ

Zakotwiczone w prawach osób z niepełnosprawnościami i w społecznym modelu niepełnosprawności.



RÓŻNICE SĄ NATURALNE

Różnice neurologiczne to naturalna i istotna część ludzkiej bioróżnorodności, a nie błędy do naprawy.



KONIEC MEDYCZYNY NAPRAWCZEJ

Sprzeciw wobec oczekiwania, że jednostki mają „pokonać”, „wyleczone” lub „naprawione”.



ODPOWIEDZIALNOŚĆ SPOŁECZEŃSTWA

To społeczeństwo musi się dostosować: dostępność, usuwanie barier, likwidacja ableizmu.



AUTONOMIA I PRZYNALEŻNOŚĆ

Szacunek dla sposobu funkcjonowania, autonomii i prawa do pełnego uczestnictwa w społeczeństwie.

4. MODEL MEDYCZNY vs MODEL SPOŁECZNY

MODEL MEDYCZNY

Problem leży w jednostce

MODEL SPOŁECZNY

Problem leży w barierach



- ✗ Deficyt do naprawy
- ✗ Diagnostyka i terapia
- ✗ „Naprawa” lub „normalizacja”
- ✗ Terapie behawioralne
- ✗ Presja na konformizm

VS



- ✓ Bariery w środowisku
- ✓ Dostępność i równość
- ✓ Zmiany systemowe
- ✓ Usuwanie barier
- ✓ Autonomia i wybór



Nie zmieniamy ludzi. Zmieniamy świat.

5. SKUTKI BRAKU ZMIAN SYSTEMOWYCH



70%

osób autystycznych doświadcza problemów ze zdrowiem psychicznym (lęk, depresja) z powodu barier społecznych i systemowych.



85%

młodych osób neuroróżnorodnych doświadcza wykluczenia w edukacji przynajmniej raz w swojej ścieżce szkolnej.



>50%

osób neuroatypowych jest bezrobotnych lub niedostatecznie zatrudnionych.



2–2,5x

większe ryzyko myśli samobójczych u osób neuroróżnorodnych w porównaniu do populacji ogólnej.

Źródła: WHO, CDC, UNICEF, OECD, Lancet Psychiatry, 2020–2024

6. PRAWDZIWE WSPARCIE (NEURO-AFFIRMING PRACTICE)



**DOSTĘPNOŚĆ
SENSORYCZNA**

Przestrzenie i narzędzia dostosowane do potrzeb sensorycznych.



**DOSTĘPNOŚĆ
SPOŁECZNA**

Równe traktowanie, brak dyskryminacji, akceptacja różnic komunikacyjnych.



**ZMIANA
SYSTEMOWA**

Likwidacja barier i polityk wykluczających.



**AUTONOMIA
I WYBÓR**

Szacunek dla decyzji, granic i sposobu funkcjonowania.



**UDZIAŁ OSÓB
NEURORÓŻNORODNYCH**

Współtworzenie rozwiązań z osobami, których dotyczą decyzje.



**PRZYNALEŻNOŚĆ
BEZ WARUNKÓW**

Poczucie przynależności niezależnie od poziomu produktywności.

Neuroróżnorodność LITE: miła nazwa, prawdziwa szkoda

Neurodiversity Lite to powierzchowne używanie języka neuroróżnorodności bez zmiany praktyk, struktur i relacji władzy.

BRZMI DOBRZE



- Inkluzywność
- Akceptacja
- Różnorodność
- Neurodiversity
- Wyjątkowe talenty
- Nowe perspektywy

MÓWI JĘZYKIEM
NEURORÓŻNORODNOŚCI

ALE W PRAKTYCE



- Brak realnej dostępności
- Brak zmian w kulturze organizacyjnej
- Brak władzy i współdecydowania
- Fokus na produktywności, nie na ludziach
- Osoby neuroróżnorodne muszą się dostosować

ZACHOWUJE STATUS QUO



MARKETING I PR

Używają neuroróżnorodności do budowania wizerunku nowoczesnej i inkluzywnej marki.



TALENT WASHING

Podkreślają „wyjątkowe talenty” garstki osób neuroróżnorodnych, ignorując bariery systemowe.



DOKUMENTY BEZ DZIAŁANIA

Polityki, deklaracje i szkolenia bez realnych zmian w procesach, narzędziach i oczekiwaniach.



TOKENSYZM

Osoby neuroróżnorodne są zapraszane do rozmowy, ale nie do podejmowania decyzji.



UKRYCIE PROBLEMU

Winą za trudności obarcza jednostkę („trzeba się bardziej starać”, „pracować nad umiejętnościami społecznymi”).



UTRZYMUJE BARIERY SYSTEMOWE

Nie zmienia środowiska, które wyklucza i przeciąża neuroróżnorodne osoby.



POGARSZA ZAUFANIE

Puste obietnice prowadzą do rozczarowania, wypalenia i wycofania.



WYKORZYSTUJE OSOBY NEURORÓŻNORODNE

Ich historie i tożsamości stają się narzędziem do budowania zysków i reputacji.



ZATRZYMUJE ZMIANĘ

Status quo pozostaje, a prawdziwa inkluzja jest odsuwana w nieskończoność.



WYRZĄDZA REALNĄ SZKODĘ

Prowadzi do przeciążeń, problemów zdrowotnych, utraty pracy i poczucia bycia „niewystarczającym”.



4. PRAWDZIWE PODEJŚCIE AFIRMUJĄCE NEURORÓŻNORODNOŚĆ (NEURODIVERSITY-AFFIRMING PRACTICE)

Nie chodzi o ludzi neuroróżnorodnych dopasowujących się do systemu, ale o zmianę systemu, aby wszyscy mogli w nim dobrze funkcjonować.



WSPÓŁPROJEKTOWANIE

Osoby neuroróżnorodne współautorami decyzji, polityk i rozwiązań.



DOSTĘPNOŚĆ SYSTEMOWA

Projektowanie dla różnych sposobów komunikacji, przetwarzania i pracy.



ELASTYCZNOŚĆ I AUTONOMIA

Różne potrzeby są normą, a nie wyjątkiem.



SZACUNEK I RELACJE

Budowanie kultury opartej na zaufaniu, empatii i bezpieczeństwie.



ODPOWIEDZIALNOŚĆ I TRANSPARENTNOŚĆ

Mierzenie postępów, uwzględnianie feedbacku, realna odpowiedzialność.

ZMIANA PARADYGMATU

Od inkluzji symbolicznej do inkluzji transformacyjnej

5. SYGNAŁY OSTRZEGAWCZE – CZY TO NEURODIVERSITY LITE?



KAMPAKIE WIZERUNKOWE VS. RZECZYWISTOŚĆ

Błyszące PR, ale środowisko pracy pozostaje niedostępne, sztywne i wrogie wobec różnic.



SUPERMOCE I PRODUKTYWNOŚĆ

Skupienie na „unikalnych umiejętnościach”, ignorowanie realnych wyzwań i przeciążeń sensorycznych.



JĘZYK BEZ DZIAŁANIA

Slogany typu „inny, nie gorszy”, ale brak zmian w barierach i praktykach rekrutacyjnych.



TOKENIZM

Wybrane osoby jako „wizytówki” sukcesu, redukcja do tego, co mogą zaoferować rynkowi.



ODGÓRNA KONTROLA

Decyzje o inkluzji podejmowane przez neurotypowe osoby, bez współtworzenia ze społecznością.



WARUNKOWA AKCEPTACJA

Przynależność zależy od dopasowania do standardów lub „użyteczności” cech.



BRAK AUTONOMII I SPRAWCZOŚCI

Ukryta kontrola i wymuszanie konformizmu pod przykrywką nowoczesnego języka.

6. DLACZEGO NARRACJA „SUPERMOCY” JEST SZKODLIWA



NIEREALNA PRESJA
Wymóg ciągłego



WYMAZYWANIE
Marginalizuje osoby



TOKENIZM
Promowanie tylko



UNIKANIE
ODPOWIEDZIALNOŚCI



I HIERARCHIE
WARUNKOWOŚĆ

7. DLACZEGO PODEJŚCIA BEHAVIORALNE SĄ SZKODLIWE (np. ABA, PBS)



MODEL DEFICYTÓW



KONTROLA, NIE AUTONOMIA



IGNOROWANIE PRZYCZYN



SPRZECZNOŚĆ Z PRAKTYKĄ



MASKOWANIE KRZYWDY

Przykłady systemów neurodiversity-sensitive

Neurodiversity-AWARE

Rozpoznaje różnice w stylach komunikacji i profilach sensorycznych; unika założenia jednego wzorca normatywnego.

Neurodiversity-SENSITIVE

Modyfikuje zachowanie systemu w odpowiedzi na te różnice: tempo, kanał sensoryczny, styl promptowania.

Neurodiversity-AFFIRMING

Traktuje odmienność jako legalną wariację, a nie deficyt do korekty. Zmienia funkcję celu i kryteria ewaluacji.

Problem podwójnej empatii (Milton, 2012): robot zoptymalizowany pod jeden wzorzec interakcji staje się nieprzejrzysty dla użytkowników ukształtowanych przez inną normę.

Ramy inkluzywne: 6 wymiarów

1. Percepcja i niepewność

inference pod niepewnością, abstention, calibration

2. Czytelność afordancji

jak robot komunikuje stan, intencje i granice

3. Personalizacja i adaptacja

user-specific regularities, tempo, kanał, intensywność

4. Wnioskowanie przyczynowe

od sygnału do wyjaśnienia: overload, frustracja, przemęczenie

5. Neuroróżnorodność

różne normy komunikacji jako wymóg projektowy

6. Ewaluacja i dobrostan

accuracy + kalibracja + komfort + autonomia + godność

Przejdźcie od empatii przez korelację do systemów, które są zarazem **trafne, kalibrowane, zrozumiałe i bezpieczne psychologicznie.**

Filary techniczne i architektura systemu

Architektura warstwowa

Percepcja

integracja multimodalna +
estymacja stanu z niepewnością

Personalizacja

priory i parametry specyficzne
dla użytkownika

Decyzja

polityka działania względem
afektu i ryzyka kontekstowego

Ekspresja

czas, postawa, gaze
i strategia werbalna

Trzy filary techniczne

1. Dane + niepewność

Dataset reprezentatywny, confidence
thresholds, abstention i escalation.

2. Personalizacja online

Brak jednego mapowania sygnał→znaczenie;
adaptacja tempa, kanału i intensywności.

3. Przyczynowość + ewaluacja

Accuracy to za mało: potrzebne kalibracja,
komfort, autonomia i dobrostan.

Konsekwencja dla inżynierii: system musi regulować nie tylko to, co wnioskuje,
ale także jak pewnie na tym działa i jak łatwo daje się skorygować użytkownikowi.

Przykłady systemów neurodiversity-sensitive

KASPAR

minimalistyczny humanoid

Projekt rozwijany przez lata zgodnie z wymaganiami użytkowników. Terapia i edukacja dzieci z ASD; wzorzec user-driven design.

(A)MICO

urządzenie multimodalne

Co-design z pracownikami autystycznymi. Redukcja przestymulowania i wzrost inkluzji w miejscu pracy.

JARI

modularny robot zoomorficzny


Utrzymane zaangażowanie u dzieci z ASD. Ambiwalentna forma zmniejsza presję interpretacyjną i ułatwia kontakt.

CoCoCo / Co3

zestawy do co-designu

Dorośli autystyczni mogą współprojektować roboty, jeśli dostarczymy scaffolding i naprawdę inkluzyjny proces.

Dynamiczny model emocji, dynamic Bayesian Network



Notacja

- z_t – stan emocjonalny (ukryty)
- C_t – kontekst w chwili t
- x_t – wektor sygnałów (wielomodalny)
- o_t – wektor obserwacji (cechy)
- a_t – działanie agenta (opcjonalnie kontrolujące przejścia i sygnały)


Faktoryzacja wspólnej dystrybucji (łańcuch Markowa 1. rzędu)

$$P(z_{1:T}, x_{1:T}, o_{1:T} | C_{1:T}, a_{1:T-1}) = P(z_1 | C_1) \prod_{t=1}^{T-1} P(z_{t+1} | z_t, C_t, a_t) \prod_{t=1}^T P(x_t | z_t, C_t, a_t) P(o_t | x_t)$$


Założenia modelu

- Emocja jest stanem ukrytym zmieniającym się w czasie.
- Kontekst wpływa zarówno na emocję, jak i na generację sygnałów.
- Sygnały (wielomodalne) są generowane przez emocję w danym kontekście.
- Obserwacje są funkcją sygnałów (np. cech ekstrakcyjnych).

World models: VAE → MDM-RNN → Controller



ECPR: Emotion-context reinforced planner



LEGENDA

- Przepływ główny
- - -> Przepływ informacji (alternatywny)
- - -> Uczenie / sprzężenie zwrotne

BELIEF STATE b_t

Rozkład probabilistyczny nad stanem ukrytym:

$$b_t(s_t) = P(s_t | o_t, m_t)$$

$$s_t = (e_t, i_t, n_t, r_t, c_t, q_t)$$

FUNKCJA NAGRODY R (EMOCJONALNO-KONTEKSTOWA)

Adekwatność emocjonalna	Spójność społeczna	Skuteczność zadaniowa	Bezpieczeństwo / ryzyko	Koszt wysiłku
R_{emo}	R_{soc}	R_{task}	R_{risk}	R_{effort}
😊	👥	🎯	🛡️	🕒




ZAMKNIĘTA PĘTLA ECPR

- Ciągła obserwacja i aktualizacja belief state
- Planowanie w oparciu o kontekst i emocje
- Jawną bramką epistemiczną (bezpieczeństwo poznawcze)
- Uczenie z nagrody zależnej od adekwatności emocjonalnej

KORZYŚCI


- Mniej błędnych reakcji
- Większe zaufanie użytkownika
- Naturalne, empatyczne interakcje
- Bezpieczne i adaptacyjne działanie

CASIE-2: Architektura przyczynowo-kontekstowa emocji




Architektura z epistemiczną pokorą

Pełny potok decyzyjny: od wejścia multimodalnego do działania, dopytania lub abstencji



Autorski framework: SAPIENS

Socially-aware, probalistic, intent-aware, epistemically-calibrated, neuro-symbolic system



Wnioski

- Robotyka afektywna musi wyjść poza empatię przez korelację.
- Trzy główne bariery to luka benchmark–wdrożenie, asymetria epistemiczna i nieadekwatność ewaluacji.
- Neuroróżnorodność nie jest przypadkiem brzegowym, lecz pierwszorzędowym ograniczeniem projektowym.
- Ramy inkluzywne łączą percepcję probabilistyczną, skalibrowaną niepewność, personalizację i wnioskowanie przyczynowe.
- Sukces systemu to nie tylko trafność klasyfikacji, ale zachowanie godności, redukcja stresu i wsparcie dobrostanu użytkownika.

Beyond Empathy by Correlation

Ku inkluzywnej robotyce afektywnej w realnej interakcji

dr inż. Mateusz Pomianek

Katedra Informatyki i Automatyki
Politechnika Rzeszowska



Chciałbym dziś przedstawić główną tezę mojego artykułu: współczesna robotyka afektywna osiąga coraz lepsze wyniki w rozpoznawaniu emocji, ale to wciąż nie oznacza, że dobrze rozumie człowieka w realnej interakcji.

Punktem wyjścia jest obserwacja, że wiele systemów działa dobrze na benchmarkach, natomiast znacznie gorzej radzi sobie w środowisku rzeczywistym, gdzie pojawia się kontekst, niejednoznaczność, szum sensoryczny, różnice indywidualne i neuroróżnorodność.

Moja propozycja jest następująca: zamiast myśleć o robotyce afektywnej wyłącznie jako o problemie klasyfikacji emocji, powinniśmy traktować ją jako problem inkluzywnego rozumienia społecznego w warunkach niepewności.

Dlaczego afektywna robotyka humanoidalna?

Nowe role robotów

Edukacja, terapia, opieka i przestrzeń domowa: sukces zależy nie tylko od wykonania zadania, ale od jakości percepcji i bezpieczeństwa emocjonalnego.

Oczekiwania społeczne

Humanoidy prowokują interpretację interpersonalną: gest, spojrzenie, proksemika i timing są odczytywane jak sygnały partnera społecznego.

Rosnące możliwości

Stan pola jest mocny technicznie: 92.1% F1 w ECRP, 97% w dialogu live i +12.5% po uczeniu interaktywnym, ale to nie rozwiązuje problemu wdrożenia.

Kluczowa teza: kompetencja techniczna musi być uzupełniona epistemiczną pokorą, partycypacyjnym projektowaniem i zasadami potwierdzającymi neuroróżnorodność.

Dlaczego ten temat jest dziś istotny? Po pierwsze dlatego, że roboty przestają być wyłącznie narzędziami wykonującymi zadania. Coraz częściej pojawiają się w edukacji, terapii, opiece i środowisku domowym, czyli tam, gdzie liczy się nie tylko skuteczność działania, ale również jakość interakcji i bezpieczeństwo psychologiczne użytkownika. Po drugie, roboty humanoidalne generują określone oczekiwania społeczne. Gaze, postura, timing, dystans interpersonalny czy ton wypowiedzi sprawiają, że użytkownik zaczyna interpretować system nie jak zwykłe urządzenie, ale jak partnera interakcji. To tworzy zarówno ogromny potencjał, jak i poważne ryzyko błędnych oczekiwań. Po trzecie, technicznie pole bardzo mocno się rozwinęło. W artykule przywołuję systemy osiągające około 92.1% F1, 97% accuracy w testach live czy wzrost jakości rozpoznawania dzięki uczeniu interaktywnemu. Problem polega jednak na tym, że te wyniki nie rozwiązują jeszcze pytania o adekwatność zachowania w świecie rzeczywistym. Kluczowa teza tego slajdu jest prosta: kompetencja techniczna nie wystarczy. Musi być uzupełniona epistemiczną pokorą, partycypacyjnym projektowaniem i zasadami potwierdzającymi neuroróżnorodność.

Luka benchmark, a wdrożenie

Środowisko testowe

- kontrolowane datasety
- pozowane lub aktorskie ekspresje
- wąska pula uczestników
- uproszczone warunki sensoryczne
- metryki: accuracy, F1, latency



Środowisko wdrożenia

- zmienność kontekstowa i szum
- stany afektywne zmieszane z zadaniem
- użytkownicy neurozróżnicowani
- shift dystrybucji względem treningu
- koszty: godność, bezpieczeństwo, dobrostan

Porażka w robotyce afektywnej nie jest neutralna: błędna interpretacja może skierować doświadczenie użytkownika w stronę odwrotną do intencji systemu.

Uporządkujmy podstawowy krajobraz pojęciowy. W robotyce afektywnej funkcjonują co najmniej cztery tradycje reprezentacji emocji. Modele dyskretne są łatwe operacyjnie, ale upraszczają stany mieszane. Modele wymiarowe, takie jak valence-arousal, dobrze wspierają sterowanie ciągłe, ale bywają zbyt abstrakcyjne społecznie. Podejścia konstruktywistyczne są teoretycznie bogatsze, jednak trudniejsze do implementacji w czasie rzeczywistym. W praktyce najlepiej działają strategie hybrydowe.


Druga kwestia to multimodalność. Realne systemy nie opierają się wyłącznie na twarzy. Integrują mowę, ruch, postawę, czasem sygnały fizjologiczne i kontekst zadaniowy. To zazwyczaj poprawia wyniki, ale nie eliminuje problemu niepewności interpretacyjnej. Kluczowe pojęcie na tym slajdzie to affective loop. Robot nie tylko wykrywa stan użytkownika, ale staje się częścią pętli, w której jego reakcja wpływa na użytkownika, a tym samym zmienia kolejny stan, który system próbuje odczytać. Innymi słowy: to nie jest klasyfikacja jednego obrazka, tylko układ dynamiczny. I właśnie dlatego nawet bardzo dobre metryki offline nie gwarantują dobrej interakcji.

Architektury emocji

1 PRZEPŁYW INFORMACJI I PODEJMOWANIE DECYZJI


✗ SYSTEM KORELACYJNY

Podejście korelacyjne (czarna skrzynka)



✓ ARCHITEKTURA PRZYZYNOWO-KONTEKSTOWA


Wnioskowanie z uwzględnieniem przyczyn i kontekstu



2 PORÓWNANIE WŁAŚCIWOŚCI ARCHITEKTUR

KRYTERIUM	SYSTEM KORELACYJNY (czarna skrzynka)	ARCHITEKTURA PRZYZYNOWO-KONTEKSTOWA
Źródło sygnału	Płaskie cechy z danych (statystyczne współwystępowanie)	Wielomodalne + kontekst + wiedza (przyczyny)
Mechanizm	Dopasowanie wzorca (fitting korelacji)	Wnioskowanie przyczynowe (model świata / SCM / DBN)
Uogólnianie (O.O.D.)	Słabe	Silne (lepszą odporność na zmianę kontekstu)
Odporność na fałszywe skróty	Niska	Wysoka
Kalibracja pewności	Często źle skalibrowana	Jawna, możliwa do kalibracji
Wyjaśnialność	Niska (nieprzejrzyste decyzje)	Wysoka (jawne przyczyny i zależności)
Bezpieczeństwo	Niskie (brak mechanizmu abstencji)	Wysokie (abstencja / eskalacja / weryfikacja)

PROFIL ARCHITEKTUR (skala 0–5)



I tu pojawia się rzecz metodologicznie najważniejsza: porażka w robotyce afektywnej nie jest neutralna. Fałszywie wykryty distress może prowadzić do intruzywnej interwencji, a fałszywie rozpoznane zaangażowanie może sprawić, że system przeoczy realne przeciążenie użytkownika. Zatem pytanie nie brzmi tylko „czy model jest trafny?”, ale „czy potrafi fail gracefully w sytuacji społecznie wrażliwej?”.

Affective loop jako rdzeń interakcji

1. REPREZENTACJE EMOCJI – JAK MODELE ROZUMIEJĄ AFEKT?

A. MODELE DYSKRETNE


Kategorie podstawowe
(np. Ekman, Plutchik)



+ interpretowalność
– sztywne granice

B. MODELE WYMIAROWE

Przestrzeń ciągła
(np. valence-arousal-dominance)



+ uchwyt dynamiki
– trudniejsza interpretacja

C. MODELE KONSTRUKTYWISTYCZNE

Emocje jako konstrukty
znaczeniowe i społeczne



+ kontekst i znaczenie
– zależność od ramy


D. MODELE HYBRYDOWE

Połączenie kategorii,
wymiarów i kontekstu



+ elastyczność
i bogactwo
– złożoność obliczeniowa

2. AFFECTIVE LOOP – RDZEŃ INTERAKCJI



Ciągłe współkształtowanie stanu afektywnego i relacji

3A. ŚRODOWISKO TESTOWE (LABORATORYJNE)

- ✓ Dobre oczyszczenie danych
- ✓ Czytelne wyrażenia emocji
- ✓ Ograniczona pula uczestników
- ✓ Często neurotypowi uczestnicy
- ✓ Uproszczone warunki sensoryczne
- ✓ Kontrolowany kontekst zadania

METRYKI KLASYCZNE



Sensowne w warunkach i.i.d.
i przy stabilnej dystrybucji danych

PRZEJŚCIE
DO RZECZYWISTEGO
WDROŻENIA
Distribution Shift
i złożoność świata

3B. ŚRODOWISKO WDROŻENIA (REAL-WORLD)

- ⚠ Afekt miesza się z zadaniem i kontekstem
- ⚠ Przeciężenie sensoryczne, zakłócenia
- ⚠ Historia interakcji i oczekiwania
- ⚠ Różnice indywidualne i kulturowe
- ⚠ Szum, ambiguita i niepełne obserwacje
- ⚠ Distribution shift (czasu, miejsca, populacji)

WCZORAJ TRAFNY MODEL MOŻE:

- ✗ generować nieadekwatne reakcje
- ✗ być nierobustny wobec nowych użytkowników
- ✗ utrzymywać uprzedzenia i wykluczenia
- ✗ nie wychwycić realnego distressu
- ✗ nadmiernie interweniować lub intrudować

METRYKI NIETYRZAJĄCE



Nie odzwierciedlają skutków społecznych i bezpieczeństwa


4. PORĄDKA W ROBOTYCE AFEKTYWNEJ NIE JEST NEUTRALNA

FALSZYWY DISTRESS (FP)



Ryzyko: intruzyjna interwencja,
utrata zaufania, eskalacja stresu

FALSZYWE ZAANGAŻOWANIE (FN)



Ryzyko: przeoczenie przeciżenia,
pogorszenie dobrostanu, możliwa szkoda

PYTANIE METODOLOGICZNE, NIE TYLKO TECHNICZNE:

„Czy model jest trafny?”
czy raczej

„Czy potrafi fail gracefully
w sytuacji społecznie wrażliwej?”

5. ZASADY PROJEKTOWE DLA PĘTLI AFEKTYWNEJ

- Uprzywilejowanie bezpieczeństwa społecznego – minimalizacja ryzyk niekorzystnych skutków.
- Kalibracja niepewności i świadomość ograniczeń – pewność modelu ≠ pewność decyzji.
- Projektowanie dla abstencji i dopytania – „nie wiem” jest lepsze niż błąd kosztowny.
- Personalizacja i uczenie relacyjne – poznanie użytkownika w czasie.
- Wielowymiarowa ewaluacja – skuteczność, dobrostan, zaufanie, sprawiedliwość, nierówności.

„Tutaj proponuję patrzeć na emocje nie jako na jednorazowy obiekt do klasyfikacji, ale jako na część pętli afektywnej. Po lewej pokazuję cztery główne rodziny reprezentacji emocji: modele dyskretne, wymiarowe, konstruktywistyczne i hybrydowe. Każda z nich uchwytuje inny aspekt afektu. Natomiast po prawej widać właściwy sens tego slajdu, czyli affective loop: percepcję, inferencję afektywną, decyzję afektywną, działanie systemu, reakcję użytkownika i aktualizację modelu. To zamknięty cykl, w którym stan afektywny i relacja są stale współkształtowane przez obie strony interakcji. Dlatego nie wystarczy rozpoznać emocję. Trzeba rozumieć, jak nasze działanie zmieni użytkownika, jego stan, jego komfort i jego zaufanie.”

Koszt błędu w robotyce afektywnej

False positive

System błędnie przypisuje użytkownikowi stan afektywny.

Ryzyko

intruzywna lub nieadekwatna interwencja, naruszenie komfortu i godności.

False negative

System nie rozpoznaje rzeczywistego przeciążenia, stresu lub dystresu.

Ryzyko

brak wsparcia tam, gdzie jest ono potrzebne; eskalacja napięcia.

Uncertainty failure

System komunikuje kruchą inferencję z nadmierną pewnością.

Ryzyko


użytkownik traktuje zawodny osąd jako wiarygodny; spadek bezpieczeństwa interakcji.

W HRI nie wystarczy pytać, **czy model jest trafny**; trzeba pytać, **czy potrafi bezpiecznie mylić** się w sytuacjach społecznie wrażliwych.

Warto doprecyzować, że w robotyce afektywnej nie każdy błąd ma ten sam ciężar. Fałszywie dodatnia inferencja może prowadzić do niepotrzebnej, a nawet intruzywnej interwencji. Fałszywie ujemna może sprawić, że system nie zareaguje tam, gdzie użytkownik realnie doświadcza przeciążenia lub dystresu. Jest jeszcze trzeci typ problemu: błędne obchodzenie się z niepewnością, czyli sytuacja, w której system komunikuje bardzo kruchy osąd z nadmierną pewnością.

I właśnie dlatego w HRI nie wystarczy pytać o **accuracy**. Trzeba pytać, czy system potrafi mylić się w sposób bezpieczny i społecznie adekwatny.

Asymetria epistemiczna w „Empatii przez korelację”



Tutaj przechodzę z poziomu problemu inżynierskiego na poziom problemu poznawczego.


Ludzkie rozumienie społeczne jest ucieleśnione, intencjonalne, osadzone w pamięci, oczekiwaniach i pragmatyce. Nie polega na biernym dekodowaniu sygnałów, tylko na aktywnym konstruowaniu znaczenia w konkretnej sytuacji.

Robot działa inaczej. Operuje na numerycznych reprezentacjach i uczy znaczenia statystycznie z danych treningowych. Może zatem osiągnąć sukces korelacyjny, ale nadal nie rozumieć pragmatycznego sensu zachowania użytkownika.

To właśnie nazywam asymetrią epistemiczną. I ważna uwaga: tej luki prawdopodobnie nie domkniemy większą ilością danych czy lepszą klasyfikacją sygnałów. Potrzebna jest zmiana sposobu projektowania systemu — tak, aby nie mylił korelacji z rozumieniem.

Implikacja projektowa jest brutalnie prosta: system może poprawnie rozpoznać smutek, przeciążenie czy napięcie, a mimo to błędnie odczytać, co te sygnały znaczą w konkretnej interakcji.

Neuroróżnorodność, jako ograniczenie projektowe



Na tym etapie wchodzimy w najważniejszy wymiar normatywny i projektowy. Moja teza jest taka, że neuroróżnorodność nie powinna być traktowana jako przypadek brzegowy, lecz jako ograniczenie pierwszego rzędu dla architektury systemu. Rozróżniam tu trzy poziomy. Poziom pierwszy to neurodiversity-aware: system uznaje, że użytkownicy różnią się komunikacyjnie i sensorycznie, więc nie zakłada jednego normatywnego wzorca. Poziom drugi to neurodiversity-sensitive: system potrafi już dostosować tempo, sposób promptowania czy kanał sensoryczny.

Poziom trzeci to neurodiversity-affirming: najbardziej wymagający, bo oznacza nie tylko adaptację, ale zmianę norm ukrytych w systemie. Odmienność nie jest tu traktowana jako deficyt do korekcji, tylko jako prawomocna wariacja.

W tym miejscu szczególnie ważny jest problem podwójnej empatii. System zoptymalizowany pod jeden model komunikacji może stać się nieczytelny i niesprawiedliwy wobec użytkowników funkcjonujących według innej logiki interakcyjnej.

Neuroróżnorodność LITE: miła nazwa, prawdziwa szkoda

Neurodiversity Lite to powierzchowne używanie języka neuroróżnorodności bez zmiany praktyk, struktur i relacji władzy.

BRZMI DOBRZE



- Inkluzywność
- Akceptacja
- Różnorodność
- Neurodiversity
- Wyjątkowe talenty
- Nowe perspektywy

MÓWI JĘZYKIEM
NEURORÓŻNORODNOŚCI

ALE W PRAKTYCE



- Brak realnej dostępności
- Brak zmian w kulturze organizacyjnej
- Brak władzy i współdecydowania
- Fokus na produktywności, nie na ludziach
- Osoby neuroróżnorodne muszą się dostosować

ZACHOWUJE STATUS QUO



MARKETING I PR

Używają neuroróżnorodności do budowania wizerunku nowoczesnej i inkluzywnej marki.



TALENT WASHING

Podkreślają „wyjątkowe talenty” garstki osób neuroróżnorodnych, ignorując bariery systemowe.



DOKUMENTY BEZ DZIAŁANIA

Polityki, deklaracje i szkolenia bez realnych zmian w procesach, narzędziach i oczekiwaniach.



TOKENIZM

Osoby neuroróżnorodne są zapraszane do rozmowy, ale nie do podejmowania decyzji.



UKRYCIE PROBLEMU

Winą za trudności obarcza jednostkę („trzeba się bardziej starać”, „pracować nad umiejętnościami społecznymi”).



UTRZYMUJE BARIERY SYSTEMOWE

Nie zmienia środowiska, które wyklucza i przeciąża neuroróżnorodne osoby.



POGARSZA ZAUFANIE

Puste obietnice prowadzą do rozczarowania, wypalenia i wycofania.



WYKORZYSTUJE OSOBY NEURORÓŻNORODNE

Ich historie i tożsamości stają się narzędziem do budowania zysków i reputacji.



ZATRZYMUJE ZMIANĘ

Status quo pozostaje, a prawdziwa inkluzja jest odsuwana w nieskończoność.



WYRZĄDZA REALNĄ SZKODĘ

Prowadzi do przeciążeń, problemów zdrowotnych, utraty pracy i poczucia bycia „niewystarczającym”.



4. PRAWDZIWE PODEJŚCIE AFIRMUJĄCE NEURORÓŻNORODNOŚĆ (NEURODIVERSITY-AFFIRMING PRACTICE)

Nie chodzi o ludzi neuroróżnorodnych dopasowujących się do systemu, ale o zmianę systemu, aby wszyscy mogli w nim dobrze funkcjonować.



WSPÓŁPROJEKTOWANIE

Osoby neuroróżnorodne współautorami decyzji, polityk i rozwiązań.



DOSTĘPNOŚĆ SYSTEMOWA

Projektowanie dla różnych sposobów komunikacji, przetwarzania i pracy.



ELASTYCZNOŚĆ I AUTONOMIA

Różne potrzeby są normą, a nie wyjątkiem.



SZACUNEK I RELACJE

Budowanie kultury opartej na zaufaniu, empatii i bezpieczeństwie.



ODPOWIEDZIALNOŚĆ I TRANSPARENTNOŚĆ

Mierzenie postępów, uwzględnianie feedbacku, realna odpowiedzialność.



ZMIANA PARADYGMATU

Od inkluzji symbolicznej do inkluzji transformacyjnej

5. SYGNAŁY OSTRZEGAWCZE – CZY TO NEURODIVERSITY LITE?



KAMPAKIE WIZERUNKOWE VS. RZECZYWISTOŚĆ

Błyszczące PR, ale środowisko pracy pozostaje niedostępne, sztywne i wrogie wobec różnic.



SUPERMOCE I PRODUKTYWNOŚĆ

Skupienie na „unikalnych umiejętnościach”, ignorowanie realnych wyzwań i przeciążeń sensorycznych.



JĘZYK BEZ DZIAŁANIA

Slogany typu „inny, nie gorszy”, ale brak zmian w barierach i praktykach rekrutacyjnych.



TOKENIZM

Wybrane osoby jako „wizytówki” sukcesu, redukcja do tego, co mogą zaoferować rynkowi.



ODGÓRNA KONTROLA

Decyzje o inkluzji podejmowane przez neurotypowe osoby, bez współtworzenia ze społecznością.



WARUNKOWA AKCEPTACJA

Przynależność zależy od dopasowania do standardów lub „użyteczności” cech.



BRAK AUTONOMII I SPRAWCZOŚCI

Ukryta kontrola i wymuszanie konformizmu pod przykrywką nowoczesnego języka.

6. DLACZEGO NARRACJA „SUPERMOCY” JEST SZKODLIWA



NIEREALNA PRESJA

Wymóg ciągłego



WYMAGIWIENIE

Marginalizuje osoby



TOKENIZM

Promowanie tylko



UNIKANIE

ODPOWIEDZIALNOŚCI



I HIERARCHIE

WARUNKOWOŚĆ



MODEL DEFICYTÓW



KONTROLA, NIE AUTONOMIA



IGNOROWANIE PRZYCZYN



SPRZECZNOŚĆ Z PRAKTYKĄ



MASKOWANIE KRZYWDY

Przykłady systemów neurodiversity-sensitive

Neurodiversity-AWARE

Rozpoznaje różnice w stylach komunikacji i profilach sensorycznych; unika założenia jednego wzorca normatywnego.

Neurodiversity-SENSITIVE

Modyfikuje zachowanie systemu w odpowiedzi na te różnice: tempo, kanał sensoryczny, styl promptowania.

Neurodiversity-AFFIRMING

Traktuje odmiennność jako legalną wariację, a nie deficyt do korekty. Zmienia funkcję celu i kryteria ewaluacji.

Problem podwójnej empatii (Milton, 2012): robot zoptymalizowany pod jeden wzorzec interakcji staje się nieprzejrzysty dla użytkowników ukształtowanych przez inną normę.

Na tym etapie wchodzimy w najważniejszy wymiar normatywny i projektowy. Moja teza jest taka, że neuroróżnorodność nie powinna być traktowana jako przypadek brzegowy, lecz jako ograniczenie pierwszego rzędu dla architektury systemu. Rozróżniam tu trzy poziomy. Poziom pierwszy to neurodiversity-aware: system uznaje, że użytkownicy różnią się komunikacyjnie i sensorycznie, więc nie zakłada jednego normatywnego wzorca. Poziom drugi to neurodiversity-sensitive: system potrafi już dostosować tempo, sposób promptowania czy kanał sensoryczny. Poziom trzeci to neurodiversity-affirming: najbardziej wymagający, bo oznacza nie tylko adaptację, ale zmianę norm ukrytych w systemie. Odmiennność nie jest tu traktowana jako deficyt do korekcji, tylko jako prawomocna wariacja.

W tym miejscu szczególnie ważny jest problem podwójnej empatii. System zoptymalizowany pod jeden model komunikacji może stać się nieczytelny i niesprawiedliwy wobec użytkowników funkcjonujących według innej logiki interakcyjnej.

Ramy inkluzywne: 6 wymiarów

1. Percepcja i niepewność

inference pod niepewnością, abstention, calibration

2. Czytelność afordancji

jak robot komunikuje stan, intencje i granice

3. Personalizacja i adaptacja

user-specific regularities, tempo, kanał, intensywność

4. Wnioskowanie przyczynowe

od sygnału do wyjaśnienia: overload, frustracja, przemęczenie

5. Neuroróżnorodność

różne normy komunikacji jako wymóg projektowy

6. Ewaluacja i dobrostan

accuracy + kalibracja + komfort + autonomia + godność

Przejdźcie od empatii przez korelację do systemów, które są zarazem **trafne, kalibrowane, zrozumiałe i bezpieczne psychologicznie.**

Tutaj syntetyzuję główny wkład artykułu. Proponowane ramy inkluzywne obejmują sześć wymiarów. Pierwszy to percepcja i niepewność, drugi — czytelność afordancji, trzeci — personalizacja i adaptacja, czwarty — wnioskowanie przyczynowe, piąty — neuroróżnorodność, a szósty — ewaluacja i dobrostan.

To nie są niezależne moduły wrzucone do jednej tabeli. To raczej współzależne osie projektowe. Jeśli na przykład poprawimy percepcję, ale nie poprawimy komunikowania niepewności, system nadal może być społecznie niebezpieczny. Jeśli dodamy personalizację, ale zachowamy ukryty normatywny model „właściwego użytkownika”, nadal będziemy wzmacniać bias architektoniczny.

Najważniejsza intuicja jest następująca: sukces w HRI nie może być mierzony wyłącznie przez trafność inferencji, lecz przez jakość relacji, bezpieczeństwo psychologiczne, zachowanie autonomii i długoterminowy dobrostan.

Filary techniczne i architektura systemu

Architektura warstwowa

Percepcja

integracja multimodalna +
estymacja stanu z niepewnością

Personalizacja

priory i parametry specyficzne
dla użytkownika

Decyzja

polityka działania względem
afektu i ryzyka kontekstowego

Ekspresja

czas, postawa, gaze
i strategia werbalna

Trzy filary techniczne

1. Dane + niepewność

Dataset reprezentatywny, confidence
thresholds, abstention i escalation.

2. Personalizacja online

Brak jednego mapowania sygnał→znaczenie;
adaptacja tempa, kanału i intensywności.

3. Przyczynowość + ewaluacja

Accuracy to za mało: potrzebne kalibracja,
komfort, autonomia i dobrostan.

Konsekwencja dla inżynierii: system musi regulować nie tylko to, co wnioskuje, ale także jak pewnie na tym działa i jak łatwo daje się skorygować użytkownikowi.

Tu chciałbym omówić **trzy najważniejsze filary** techniczne proponowanego podejścia.

- 1) Pierwszy filar to reprezentatywne dane i skalibrowana niepewność. Nie wystarczy zebrać więcej danych. Trzeba zebrać dane bardziej zróżnicowane demograficznie, neurokognitywnie i kontekstowo. Dodatkowo system powinien umieć reprezentować niepewność explicite i — kiedy dowód jest słaby — wstrzymać osąd, poprosić o doprecyzowanie lub ograniczyć intensywność interwencji.
- 2) Drugi filar to personalizacja i adaptacja online. Nie istnieje jedno stabilne mapowanie sygnału na znaczenie dla wszystkich użytkowników. Dlatego system powinien uczyć się regularności specyficznych dla użytkownika: preferowanego tempa, poziomu werbalności, ekspresji emocjonalnej, kanału sensorycznego czy stylu turn-taking.
- 3) Trzeci filar to modelowanie przyczynowe i wielowymiarowa ewaluacja. Zamiast pytać wyłącznie, z jaką etykietą koreluje sygnał, pytamy: co mogło spowodować obserwowane zachowanie? Czy mamy do czynienia z frustracją, przeciążeniem sensorycznym, zmęczeniem czy nieporozumieniem? To przesuwaa architekturę z poziomu rozpoznawania powierzchniowych wzorców na poziom bardziej adekwatnego modelowania sytuacji.

Przykłady systemów neurodiversity-sensitive

KASPAR

minimalistyczny humanoid

Projekt rozwijany przez lata zgodnie z wymaganiami użytkowników. Terapia i edukacja dzieci z ASD; wzorzec user-driven design.

(A)MICO

urządzenie multimodalne

Co-design z pracownikami autystycznymi. Redukcja przestymulowania i wzrost inkluzji w miejscu pracy.

JARI

modularny robot zoomorficzny

Utrzymane zaangażowanie u dzieci z ASD. Ambiwalentna forma zmniejsza presję interpretacyjną i ułatwia kontakt.


CoCoCo / Co3

zestawy do co-designu

Dorośli autystyczni mogą współprojektować roboty, jeśli dostarczymy scaffolding i naprawdę inkluzyjny proces.


Ten slajd pokazuje, że mówimy nie tylko o postulatach etycznych, ale o rozwiązaniach, które już istnieją. KASPAR to ważny przykład minimalnie ekspresyjnego humanoida, projektowanego przez lata z silnym uwzględnieniem wymagań użytkowników i zastosowań terapeutycznych. Jego wartość polega między innymi na tym, że ograniczona ekspresja może zmniejszać ryzyko nadinterpretacji. JARI pokazuje z kolei, że niejednoznaczna, mniej presyjna forma robota może sprzyjać zaangażowaniu dzieci z ASD i redukować obciążenie interpretacyjne. (A)MICO to przykład systemu współprojektowanego z osobami autystycznymi w kontekście pracy, którego celem jest zmniejszenie przestymulowania i poprawa inkluzji. Wreszcie CoCoCo i Co3 są ważne metodologicznie: pokazują, że osoby autystyczne nie muszą być tylko obiektami badań. Mogą być współautorami procesu projektowego, jeśli damy im odpowiedni scaffolding i dobrze zaprojektowane procedury partycypacyjne. To jest bardzo ważne przesunięcie: od „projektowania dla” na „projektowanie z”.

Dynamiczny model emocji, dynamic Bayesian Network




„Ten slajd pokazuje dynamiczny model emocji w postaci sieci bayesowskiej. W każdej chwili czasu mamy kontekst, ukryty stan emocjonalny, sygnały oraz obserwacje. Kluczowa idea polega na tym, że emocja jest stanem ukrytym, zmieniającym się w czasie, a kontekst wpływa zarówno na sam stan emocjonalny, jak i na generowane sygnały. Następnie z sygnałów otrzymujemy obserwacje, czyli to, co system faktycznie widzi. Przejścia między chwilą t i t+1 są modelowane probabilistycznie. To bardzo ważne, bo pozwala myśleć o emocji nie jako o statycznej etykiecie, ale jako o procesie dynamicznym zależnym od kontekstu i historii interakcji.”

World models: VAE → MDM-RNN → Controller




„Tutaj pokazuję architekturę world models. Najpierw wejście multimodalne jest kompresowane przez VAE do przestrzeni ukrytej. Następnie MDN-RNN pełni rolę modelu świata, przewidując kolejne stany latentne w funkcji aktualnego stanu, akcji i pamięci. Na końcu prosty kontroler wybiera działanie na podstawie reprezentacji latentnej i stanu pamięci. Najważniejsza zaleta tego podejścia jest taka, że robot może symulować przyszłość 'w głowie', zamiast kosztownie i ryzykownie testować każdą możliwość w realnej interakcji. Dzięki temu może przewidywać potencjalne skutki społeczno-emocjonalne, planować bezpieczniej i uczyć się z wyobrażenia. Ten model dobrze wspiera późniejsze decyzje personalizowane i ostrożne epistemicznie.”

ECPR: Emotion-context reinforced planner



„Tutaj przedstawiam planner ECPR, czyli Emotion-Context Reinforced Planner. Pętla zaczyna się od percepcji i wnioskowania, które prowadzą do estymacji belief state. Następnie pojawia się centralny element całej architektury, czyli bramka epistemiczna. Jeśli niepewność jest akceptowalna, system przechodzi do planowania w horyzoncie H , wybiera działanie, wykonuje je i ocenia wynik za pomocą funkcji nagrody zależnej nie tylko od skuteczności zadaniowej, ale również od adekwatności emocjonalnej. Jeśli niepewność nie jest akceptowalna, system dopytuje, prowadzi aktywną percepcję albo eskaluje sprawę. To odróżnia planner odpowiedzialny od planera optymalizującego wyłącznie zadanie. Tutaj celem jest dobra reakcja społeczna, a nie tylko maksymalizacja trafności klasyfikacji.”


CASIE-2: Architektura przyczynowo-kontekstowa emocji



„Na tym slajdzie pokazuję architekturę CASIE-2 jako bardziej kompletny system przyczynowo-kontekstowy. Mamy tu model kontekstu społecznego, warstwę kauzalną, probabilistyczny stan przekonań, warstwę kalibracji niepewności oraz warstwę bezpieczeństwa i polityki decyzyjnej. Całość składa się z przejrzystego potoku: od danych wejściowych, przez ekstrakcję cech, model kontekstu, model przyczynowy, belief state i kalibrację, aż po politykę bezpieczeństwa i działanie. To ważne, bo pokazuje, że kontekst, przyczynowość, niepewność i polityka bezpieczeństwa nie są dodatkami na końcu, ale integralnymi elementami jednej architektury.”

Architektura z epistemiczną pokorą


Pełny potok decyzyjny: od wejścia multimodalnego do działania, dopytania lub abstencji



„Tutaj syntetyzuję wcześniejsze elementy w architekturę z epistemiczną pokorą. Potok zaczyna się od wejścia multimodalnego, percepcji i fuzji, przechodzi przez belief state, korektę przyczynową i kalibrację niepewności, a następnie trafia do bramki epistemicznej. Jeśli warunki bezpieczeństwa i pewności są spełnione, system planuje i działa. Jeśli nie, dopytuje, abstynuje albo eskaluje. Chodzi o to, aby system potrafił powiedzieć 'nie wiem' w sposób funkcjonalny i społecznie bezpieczny. Epistemiczna pokora nie oznacza słabości systemu. Oznacza architekturę, która zna granice własnego poznania i potrafi odpowiednio dobrać formę działania.”

Autorski framework: SAPIENS

Socially-aware, probalistic, intent-aware, epistemically-calibrated, neuro-symbolic system



„Na tym slajdzie przedstawiam mój autorski framework SAPIENS: Socially-aware, probabilistic, intent-aware, epistemically-calibrated, neuro-symbolic system. To architektura dla robotów humanoidalnych, która łączy percepcję ucieleśnioną, pamięć i model użytkownika, probabilistyczny stan przekonań, warstwę kauzalną, kalibrację niepewności oraz planowanie i decyzję. Gdy bramka epistemiczna mówi ‚nie’, system przechodzi do akcji epistemicznych: dopytania, aktywnej percepcji lub eskalacji. Gdy mówi ‚tak’, przechodzi do wykonania, ale nadal przez safety shield. Na końcu mamy wynik, uczenie i adaptację całego systemu. SAPIENS jest próbą zebrania w jednym frameworku wszystkich wcześniejszych wątków: kontekstu społecznego, probabilistyki, przyczynowości, kalibracji, planowania i bezpieczeństwa.”

Wnioski

- Robotyka afektywna musi wyjść poza empatię przez korelację.
- Trzy główne bariery to luka benchmark-wdrożenie, asymetria epistemiczna i nieadekwatność ewaluacji.
- Neuroróżnorodność nie jest przypadkiem brzegowym, lecz pierwszorzędowym ograniczeniem projektowym.
- Ramy inkluzywne łączą percepcję probabilistyczną, skalibrowaną niepewność, personalizację i wnioskowanie przyczynowe.
- Sukces systemu to nie tylko trafność klasyfikacji, ale zachowanie godności, redukcja stresu i wsparcie dobrostanu użytkownika.

„Na koniec chcę podkreślić pięć najważniejszych wniosków. Po pierwsze, robotyka afektywna musi wyjść poza empatię przez korelację. Po drugie, trzy główne bariery to luka między benchmarkiem a wdrożeniem, asymetria epistemiczna oraz nieadekwatność klasycznej ewaluacji. Po trzecie, neuroróżnorodność nie jest przypadkiem brzegowym, ale pierwszorzędowym ograniczeniem projektowym. Po czwarte, ramy inkluzywne muszą łączyć percepcję probabilistyczną, skalibrowaną niepewność, personalizację i wnioskowanie przyczynowe. I po piąte, sukces systemu nie może być mierzony wyłącznie trafnością klasyfikacji. Musi obejmować również godność, redukcję stresu i realne wsparcie dobrostanu użytkownika. To właśnie rozumiem przez przejście od empatii przez korelację do inkluzywnej robotyki afektywnej.”